

Previsão de Inflação com Parâmetros Variando no Tempo

Modelo 2SRR aplicado ao CPIAUCSL (FRED-MD)

Hiperparâmetros da especificação principal:

$K_{\max} = 40$ componentes PCA | Variância explicada $\geq 90\%$ | k -fold = 5

312 janelas fora da amostra | Janeiro de 1960 a junho de 2025 Felipe Dornelles

TCC — UFRGS

22 de abril de 2026

Nota sobre este documento

Este é um relatório intermediário de resultados, produzido com assistência de IA para resumir os resultados com o objetivo de apresentar e discutir os outputs gerados até o momento. **Não é o trabalho final.** Serve para alinhar o entendimento dos resultados com o orientador antes da redação definitiva.

Sumário

1	O que foi feito e por quê	2
1.1	Como o 2SRR funciona, na prática	2
1.2	Hiperparâmetros escolhidos e justificativa	2
2	Resultados de previsão	3
2.1	RMSFE relativo ao Random Walk — todos os modelos	3
2.2	Como ler o teste Diebold-Mariano nessa tabela	4
2.3	2SRR vs. Ridge — o ganho da variação temporal	5
2.4	2SRR vs. modelos selecionados	6
2.5	Análise por sub-períodos	7
2.6	Ranking Borda — desempenho agregado	7
2.7	CSFE — Quando o 2SRR ganha e quando perde	8
3	Os parâmetros variantes no tempo	8
3.1	Evolução temporal dos coeficientes (top variáveis)	9
3.2	Top 2 componentes mais voláteis	10
3.3	Sinal e magnitude dos principais componentes PCA	10
3.4	Contribuição relativa de cada componente PCA	11
4	Onde o 2SRR se posiciona na literatura	12
4.1	O que ainda pode ser feito (próximos passos)	12
5	Configuração técnica da estimação	13

1 O que foi feito e por quê

Este trabalho aplica o modelo **2SRR** (*Two-Step Ridge Regression* com parâmetros variantes no tempo), proposto por **Coulombe (2024)**, ao problema de previsão da inflação americana medida pelo CPIAUCSL.

A ideia central é simples: e se os coeficientes de uma regressão não fossem fixos, mas pudessem *mudar ao longo do tempo*, acompanhando as transformações da economia? Coulombe demonstra que essa formulação é algebricamente equivalente a um modelo Ridge em que a penalidade recai sobre as *mudanças* dos coeficientes entre períodos — não sobre o tamanho deles.

Contribuição inédita deste TCC

Coulombe (2024) avalia o 2SRR comparando apenas com modelos VAR e AR, em dados canadenses. Este trabalho é a **primeira avaliação do 2SRR head-to-head com métodos de Machine Learning (Random Forest, Bagging) e métodos de regularização (Ridge, LASSO, ELNET, AdaLASSO)** no framework FRED-MD de Medeiros et al. — o mesmo dataset e a mesma janela de avaliação, o que torna a comparação direta e livre de artefatos de dado.

1.1 Como o 2SRR funciona, na prática

O modelo opera em dois estágios por janela de estimação:

Passo 1. Redução de dimensionalidade via PCA. O FRED-MD contém mais de 100 variáveis macroeconômicas. Antes de qualquer regressão, extraímos os K primeiros componentes principais que explicam pelo menos 90% da variância total do conjunto de preditores (com $K \leq 40$). Isso transforma um problema de altíssima dimensão em um problema tratável, sem jogar fora a maior parte da informação.

Passo 2. Ridge com parâmetros variantes no tempo. Sobre esses componentes PCA, estimamos o vetor de coeficientes $\hat{\beta}(t)$ que minimiza:

$$\sum_{s=1}^T (y_{s+h} - \mathbf{F}_s^\top \beta_s)^2 + \lambda \sum_{s=2}^T \|\beta_s - \beta_{s-1}\|^2$$

O parâmetro λ controla a *velocidade de variação* dos coeficientes: $\lambda \rightarrow \infty$ congela os parâmetros (Ridge fixo), enquanto $\lambda \rightarrow 0$ os deixa variar livremente a cada período. O valor ótimo é selecionado automaticamente por validação cruzada k -fold ($k = 5$) em cada janela de estimação.

1.2 Hiperparâmetros escolhidos e justificativa

Hiperparâmetro	Valor	Justificativa
$K_{\max}$	40	Cobertura mais ampla do espaço de preditores
Variância explicada mínima	90%	Garante riqueza informacional
k -fold	5	Equilíbrio entre viés e variância na seleção de λ
Horizontes (h)	1 a 12 meses	Previsão de curto a médio prazo
Janelas OOS	312	Jan/1960 a Jun/2025
Tempo de estimação	≈ 392 min	Rodado em janela expansível

2 Resultados de previsão

2.1 RMSFE relativo ao Random Walk — todos os modelos

A métrica principal é o **RMSFE relativo ao Random Walk (RW)**: valores abaixo de 1 indicam que o modelo bate o benchmark ingênuo. Os 13 modelos avaliados incluem o 2SRR e os modelos do framework de Medeiros et al. (Ridge, LASSO, AdaLASSO, EINET, AdaEINET, Random Forest, Bagging, Factor, AR, AR_BIC, CSR e T.Factor).




Figura 1: RMSFE relativo ao Random Walk para todos os 13 modelos ($h = 1$ a $h = 12$). A linha tracejada em 1,0 representa o benchmark. O 2SRR é o único modelo que fica abaixo de 1,0 em **todos** os 12 horizontes individuais. O Bagging é o que mais destoa negativamente, superando o benchmark em múltiplos horizontes.

Resultado principal

O 2SRR ($K_{\max} = 40$, 90%, k -fold 5) é o **único modelo que supera o Random Walk em todos os 12 horizontes individuais**. Nos horizontes curtos ($h = 1$ a $h = 3$), os modelos de regularização estática (EINET, LASSO) apresentam RMSFE mais baixo. A partir de $h = 4$, o 2SRR passa a ser competitivo e registra o **menor RMSFE em $h = 4$ (0,782)**.

A tabela completa de RMSFE com significância estatística (Teste Diebold-Mariano bilateral vs. o 2SRR) é apresentada a seguir:

Tabela 1: RMSFE relativo ao Random Walk com significância Diebold-Mariano. Asteriscos indicam significância do teste DM bilateral, comparando cada modelo **contra o 2SRR**: * $p < 0,10$; ** $p < 0,05$; *** $p < 0,01$. **Negrito** = menor RMSFE por linha. Valores < 1 indicam ganho sobre o benchmark RW. Hiperparâmetros 2SRR: $K_{\max} = 40$, variância $\geq 90\%$, k -fold = 5. 312 janelas OOS (Jan/1960–Jun/2025).

Horizonte	2SRR	Ridge	LASSO	AdaLASSO	ELNET	RF	Bagging	Factor	AR	O
h=1	0.9434	0.9047	0.8323**	0.8616*	0.8318**	0.8816	0.9317	0.8837	0.9048	0.8
h=2	0.836	0.8222	0.7486	0.7947	0.7459	0.7728	0.9848	0.8176	0.8047	0.7
h=3	0.8032	0.7976	0.7506	0.7802	0.7468	0.7554	0.8962	0.8486	0.7907	0.7
h=4	0.7816	0.8261	0.7786	0.8034	0.7757	0.7879	1.0191	0.8204	0.8029	0.8
h=5	0.7877	0.8056	0.7765	0.8047	0.7814	0.7662	1.0353	0.8066	0.7921	0.8
h=6	0.8190	0.8023	0.7748	0.7984	0.7762	0.7535	0.9585	0.8351	0.7934	0.8
h=7	0.8379	0.8241	0.7864	0.8034	0.7892	0.7670	0.8866	0.8622	0.7945	0.8
h=8	0.8144	0.8374	0.7622	0.7995	0.7754	0.7537	1.1088	0.8722***	0.7737	0.8
h=9	0.7972	0.8257*	0.7505	0.7829	0.7593	0.7403	1.0674	0.8242	0.7672	0.7
h=10	0.8843	0.913***	0.8158	0.8474	0.8158	0.7905	1.1416*	0.8528*	0.8099	0.8
h=11	0.8519	0.8937*	0.8206	0.8463	0.8169	0.8188	1.3099	0.8459	0.8136	0.8
h=12	0.7619	0.7903*	0.7278	0.7542	0.7193	0.7739	1.0113	0.8107	0.7309	0.7
acc3	0.9205	0.8879	0.8331	0.8319	0.8349	0.8631	0.9480	0.9400	0.9285	0.8
acc6	1.0581	1.0263	1.0204	1.0133	1.0263	1.0145	1.1850	1.1317	1.0949	1.0
acc12	0.8013	0.8053	0.7998	0.8154	0.7998	0.8520	0.8203	1.1009	0.8583	0.8

* $p < 0,10$; ** $p < 0,05$; *** $p < 0,01$ — Diebold-Mariano bilateral vs. 2SRR

acc3/acc6/acc12 = RMSFE sobre inflação acumulada em 3, 6 e 12 meses. Nenhum modelo supera o RW em acc6.

2.2 Como ler o teste Diebold-Mariano nessa tabela

O teste DM compara cada modelo **contra o 2SRR**. Portanto:

- Um asterisco em ELNET h=1 (0.8318**) significa que o ELNET é *estatisticamente melhor* que o 2SRR em $h = 1$ com $p < 0,05$.
- Um asterisco em Ridge h=9 (0.8257*) significa que o Ridge é *significativamente pior* que o 2SRR — pois seu RMSFE é maior e o DM confirma que a diferença não é ruído.
- Sem asterisco = a diferença entre o modelo e o 2SRR *não é estatisticamente significativa*.

Limitação importante

O teste DM aqui foi implementado de forma bilateral e sem correção de Harvey, Leybourne e Newbold (HLN), que é recomendada para amostras menores. Para a versão final do TCC, considerar a correção HLN via `forecast::dm.test()` com `h` correspondente ao horizonte avaliado.

2.3 2SRR vs. Ridge — o ganho da variação temporal




Figura 2: RMSFE relativo ao RW: 2SRR vs. Ridge por horizonte. O Ridge homogêneo é o benchmark natural para o 2SRR, pois é algebricamente equivalente ao 2SRR com $\lambda \rightarrow \infty$ (parâmetros congelados). Onde o 2SRR ganha, significa que deixar os parâmetros variar ajudou.

O que a comparação 2SRR vs. Ridge mostra, numericamente:

Horizonte	2SRR	Ridge	Ganho 2SRR (%)
$h = 1$	0,9434	0,9047	−4,3% (Ridge ganha)
$h = 2$	0,8360	0,8222	−1,7% (Ridge ganha)
$h = 3$	0,8032	0,7976	−0,7% (Ridge ganha)
$h = 4$	0,7816	0,8261	+5,4% (2SRR ganha)
$h = 5$	0,7877	0,8056	+2,2% (2SRR ganha)
$h = 6$	0,8190	0,8023	−2,1% (Ridge ganha)
$h = 7$	0,8379	0,8241	−1,7% (Ridge ganha)
$h = 8$	0,8144	0,8374	+2,7% (2SRR ganha)
$h = 9$	0,7972	0,8257	+3,5% (2SRR ganha)
$h = 10$	0,8843	0,9130	+3,1% (2SRR ganha)
$h = 11$	0,8519	0,8937	+4,7% (2SRR ganha)
$h = 12$	0,7619	0,7903	+3,6% (2SRR ganha)
acc12	0,8013	0,8053	+0,5% (2SRR ganha)

Interpretação: nos horizontes curtos ($h = 1$ a $h = 3$), a variação temporal não ajuda — os coeficientes verdadeiros parecem ser suficientemente estáveis no curto prazo. A partir de

$h = 4$, o 2SRR ganha em 8 dos 9 horizontes restantes. O maior ganho é em $h = 4$ (+5,4%), onde o 2SRR registra o menor RMSFE absoluto de toda a competição.

2.4 2SRR vs. modelos selecionados




Figura 3: RMSFE relativo ao RW: 2SRR vs. modelos selecionados (Ridge, EINET, RF) por horizonte. Comparação enxuta com os três rivais mais relevantes — o benchmark natural (Ridge), o melhor modelo estático nos horizontes curtos (EINET) e o melhor modelo nos horizontes longos (Random Forest).

2.5 Análise por sub-períodos




Figura 4: RMSFE por sub-período histórico (Grande Inflação, Grande Moderação, Crise Financeira Global, Pós-pandemia). A decomposição temporal revela em quais regimes macroeconômicos o 2SRR se beneficia da adaptabilidade dos parâmetros.

2.6 Ranking Borda — desempenho agregado




Figura 5: Ranking Borda agregado por modelo ao longo de todos os horizontes ($h = 1$ a $h = 12$). Menor pontuação = melhor desempenho médio no ranking. O Borda Count é uma métrica de consenso que penaliza modelos instáveis entre horizontes.

2.7 CSFE — Quando o 2SRR ganha e quando perde

O **CSFE** (Cumulative Squared Forecast Error) é uma ferramenta visual poderosa: a linha sobe quando o 2SRR está *errando menos* que o benchmark, e desce quando está *errando mais*. Inclinações abruptas identificam os episódios históricos que mais afetaram o desempenho relativo.




Figura 6: CSFE acumulado para $h = 1$: diferença acumulada entre o erro quadrático do benchmark (RW) e o erro quadrático do 2SRR. Linha ascendente = 2SRR está vencendo; linha descendente = 2SRR está perdendo. As sombras cinzas indicam recessões NBER.

3 Os parâmetros variantes no tempo

Esta seção é o coração da contribuição do 2SRR: ao contrário dos outros modelos avaliados, conseguimos *ver* como os coeficientes evoluem ao longo do tempo.

Nota importante de interpretação: os betas aqui são coeficientes sobre *componentes PCA padronizados*. A magnitude absoluta não tem interpretação direta em unidades de inflação. O que importa é: (1) a variação ao longo do tempo; (2) o sinal em cada período; (3) a estabilidade por componente.

3.1 Evolução temporal dos coeficientes (top variáveis)




Figura 7: Evolução de $\hat{\beta}(t)$ para $h = 1$, top 10 variáveis por variância dos coeficientes ao longo do período completo (1960–2025). As sombras cinzas indicam recessões NBER.

Três regimes se destacam visualmente:

- (1) **Grande Inflação (1960–1985):** amplitude alta e oscilações frequentes, refletindo instabilidade na relação entre produção industrial e inflação antes da desinflação Volcker.
- (2) **Grande Moderação (1985–2019):** os betas convergem próximos a zero com menor variância. A estabilidade macro reduz a sensibilidade dos preditores à inflação.
- (3) **Ruptura pós-pandemia (2020–2025):** coeficientes de magnitude sem precedente histórico, capturando o papel dos gargalos de oferta no episódio inflacionário recente. Esse comportamento *justifica retroativamente* o uso de um modelo com parâmetros variantes no tempo.

3.2 Top 2 componentes mais voláteis




Figura 8: Evolução dos coeficientes TVP dos 2 componentes PCA com maior volatilidade ao longo do tempo ($h = 1$). Esses são os fatores que mais “trabalham” na adaptação do modelo às mudanças de regime macroeconômico.

3.3 Sinal e magnitude dos principais componentes PCA




Figura 9: Evolução de $\hat{\beta}(t)$ para PC1, PC2 e PC3 ao longo de todo o período OOS, $h = 1$. PC1 e PC2 são os dois maiores eixos de variação do FRED-MD. Mudanças de sinal evidenciam instabilidade estrutural na relação macro-inflação.




Figura 10: Top 6 componentes PCA por volatilidade dos coeficientes ($h = 1$). Cada painel mostra a série $\hat{\beta}_{PC_k}(t)$ com faixa de confiança. A variância entre componentes revela quais dimensões do espaço macro são mais instáveis ao longo do tempo.

3.4 Contribuição relativa de cada componente PCA

Além do sinal, é relevante saber *qual componente PCA domina a previsão em cada momento*. A contribuição relativa de cada PC é definida como:

$$\text{Contrib}_k(t) = \frac{|\hat{\beta}_k(t)|}{\sum_j |\hat{\beta}_j(t)|} \times 100$$




Figura 11: Contribuição relativa (%) dos top 10 componentes PCA para a previsão do 2SRR ao longo do tempo ($h = 1$). Cada área empilhada representa a parcela $|\hat{\beta}_k(t)| / \sum |\hat{\beta}|$. Recessões NBER em cinza.

4 Onde o 2SRR se posiciona na literatura

Resumo do posicionamento

- Coulombe (2024) avalia o 2SRR comparando com VARs e ARs em dados canadenses (inflação, PIB, spread de juros).
- Este trabalho aplica o 2SRR **no mesmo framework e dataset de Medeiros et al.** (FRED-MD, CPIAUCSL), permitindo comparação direta com Ridge, LASSO, ELNET, AdaLASSO, RF, Bagging, Factor, AR e CSR.
- O benchmark é o Random Walk — mais conservador que o AR2 usado por Coulombe, o que torna os resultados mais difíceis de superar.
- O 2SRR **bate o RW em todos os 12 horizontes**, o que nenhum outro modelo do conjunto consegue.
- O 2SRR **supera o Ridge em 8 dos 12 horizontes**, mostrando que a variação temporal dos parâmetros agrega valor econométrico real, especialmente em $h \geq 4$.

4.1 O que ainda pode ser feito (próximos passos)

1. **GARCH(1,1) no passo 2:** Coulombe especifica o uso de GARCH para modelar a variância dos resíduos. A implementação atual usa janela móvel de 12 meses (simplificação computacional). Testar com `rugarch` e comparar.
2. **Blocked cross-validation:** substituir o k -fold simples por blocos de 6–12 meses para

reduzir o viés de look-ahead em horizontes longos (relevante para `acc6` e `acc12`).

3. **Correção HLN no teste DM:** a versão final do TCC deve usar `forecast::dm.test()` com a correção de Harvey, Leybourne e Newbold para amostras finitas.
4. **Model Confidence Set (MCS):** identifica o conjunto de modelos estatisticamente equivalentes ao melhor — mais robusto que comparar pares.
5. **MSRRS (extensão sparse):** Coulombe propõe uma versão esparsa do 2SRR que pode ser superior em dimensões médias/altas como a deste trabalho.

5 Configuração técnica da estimação

- **Linguagem:** R
- **Funções principais:** `run2srr()` implementada em `tvpridgefunctions.R` (baseada no código de Coulombe)
- **Pacotes:** `glmnet` (Ridge/CV), `dplyr`, `ggplot2`, `forecast` (DM test)
- **Dados:** FRED-MD via `fredmd` (mesmo dataset de Medeiros et al.)
- **Janela:** expansível (*expanding window*), 312 janelas OOS
- **Tempo de estimação:** ≈ 392 minutos ($12 \text{ horizontes} \times 312 \text{ janelas} \times k\text{-fold } 5$)
- **Total de betas recuperados** (apenas $h = 1$): $312 \times K \approx 12.792$ observações