

Previsão de Inflação com Parâmetros Variantes no Tempo

Modelo 2SRR aplicado ao CPIAUCSL

Hiperparâmetros: $K_{\max} = 40$, variância explicada = 90%, k -fold = 5, 312 janelas OOS
(1960–2025)

Felipe Dornelles

21 de abril de 2026

Sumário

1	Modelo 2SRR: Parâmetros Variantes no Tempo	3
1.1	Motivação	3
1.2	Especificação	3
1.3	Implementação	4
2	Resultados	4
2.1	RMSFE relativo ao Random Walk	4
2.2	Comparação 2SRR vs Ridge	6
2.3	Parâmetros Variantes no Tempo	8

1 Modelo 2SRR: Parâmetros Variantes no Tempo

1.1 Motivação

Os modelos de previsão com parâmetros fixos assumem que a relação entre preditores e inflação permanece estável ao longo do tempo. Contudo, eventos como a crise financeira de 2008 e o choque inflacionário pós-pandemia de 2021–2022 sugerem que essa relação é fundamentalmente instável. ? demonstra que modelos com parâmetros variantes no tempo (*time-varying parameters*, TVP) podem ser interpretados como casos especiais de regressão Ridge com penalidade sobre as mudanças dos coeficientes, o que abre caminho para estimação eficiente em grandes painéis de variáveis macroeconômicas.

1.2 Especificação

Seja y_{t+h} a inflação acumulada em h meses à frente e $\mathbf{x}_t \in \mathbb{R}^N$ o vetor de N preditores disponíveis em t . O 2SRR (*Two-Step Ridge Regression*) é estimado em dois estágios:

Estágio 1 — Redução de dimensionalidade via PCA. Os K primeiros componentes principais de $\mathbf{x}_t$ são retidos de modo a explicar ao menos 90% da variância total ($K \leq 40$):

$$\mathbf{F}_t = \mathbf{P}^\top \tilde{\mathbf{x}}_t$$

onde $\mathbf{P}$ é a matriz de autovetores e $\tilde{\mathbf{x}}_t$ é a versão padronizada de $\mathbf{x}_t$. O limiar de 90% de variância explicada, combinado com o teto de $K_{\max} = 40$ fatores, permite uma representação mais rica do espaço de preditores em relação a especificações mais parcimoniosas, ao custo de maior dimensionalidade no segundo estágio.

Estágio 2 — Ridge com parâmetros variantes no tempo. O vetor de coeficientes $\boldsymbol{\beta}(t)$ é estimado por:

$$\hat{\boldsymbol{\beta}}(\lambda) = \arg \min_{\boldsymbol{\beta}} \sum_{s=1}^T \left(y_{s+h} - \mathbf{F}_s^\top \boldsymbol{\beta}_s \right)^2 + \lambda \sum_{s=2}^T \left\| \boldsymbol{\beta}_s - \boldsymbol{\beta}_{s-1} \right\|^2$$

O parâmetro λ é selecionado por validação cruzada k -fold com $k = 5$ dobras em cada janela de estimação, seguindo a recomendação original de ?. Essa escolha oferece melhor estimativa do erro de generalização em relação a $k = 3$, ao custo de maior tempo computacional por janela. Como demonstrado por ?, essa formulação é algebricamente equivalente a um modelo TVP-Ridge, em que λ controla a velocidade de variação dos coeficientes no tempo.

1.3 Implementação

O modelo foi implementado na função `run2srr()` em R, com os seguintes hiperparâmetros — alinhados à especificação original de ?:

- Número máximo de componentes principais: $K_{\max} = 40$
- Variância explicada mínima: 90%
- Validação cruzada: $k\text{-fold} = 5$
- Horizontes estimados: $h \in \{1, 2, \dots, 12\}$ meses
- Janelas fora da amostra: 312 (janeiro de 1960 a junho de 2025)
- Tempo total de estimação: ≈ 392 minutos

Os coeficientes $\hat{\beta}(t)$ foram extraídos para cada janela e horizonte, totalizando 12.792 observações de betas para $h = 1$.

2 Resultados

2.1 RMSFE relativo ao Random Walk

A métrica de avaliação é o RMSFE relativo ao benchmark de Random Walk (RW):

$$\text{RMSFE}_{\text{rel}}(h) = \frac{\sqrt{\frac{1}{T} \sum_t (f_{t,h} - y_{t+h})^2}}{\sqrt{\frac{1}{T} \sum_t (y_t - y_{t+h})^2}}$$

Valores abaixo de 1 indicam que o modelo supera o Random Walk. A Tabela 1 apresenta os resultados completos para os 13 modelos avaliados nas 312 janelas fora da amostra.

Tabela 1: RMSFE relativo ao Random Walk — todos os modelos (312 janelas OOS, CPIAUCSL). Hiperparâmetros 2SRR: $K_{\max} = 40$, variância explicada $\geq 90\%$, k -fold = 5. **Negrito** = menor valor por linha. Valores < 1 indicam ganho sobre o benchmark RW.

Horizonte	2SRR	AdaEINET	AdaLASSO	AR	AR_BIC	Bagging	CSR	EINET	Factor	LASSO	RF	Ridge	T.Factor
$h = 1$	0,9434	0,8777	0,8616	0,9048	0,9102	0,9317	0,8473	0,8318	0,8837	0,8323	0,8816	0,9047	0,8735
$h = 2$	0,8360	0,7916	0,7947	0,8047	0,8064	0,9848	0,7600	0,7459	0,8176	0,7486	0,7728	0,8222	0,7906
$h = 3$	0,8032	0,7869	0,7802	0,7907	0,7945	0,8962	0,7666	0,7468	0,8486	0,7506	0,7554	0,7976	0,7953
$h = 4$	0,7816	0,8039	0,8034	0,8029	0,8081	1,0191	0,8040	0,7757	0,8204	0,7786	0,7879	0,8261	0,7982
$h = 5$	0,7877	0,8097	0,8047	0,7921	0,7968	1,0353	0,8118	0,7814	0,8066	0,7765	0,7662	0,8056	0,7754
$h = 6$	0,8190	0,7949	0,7984	0,7934	0,7969	0,9585	0,8135	0,7762	0,8351	0,7748	0,7535	0,8023	0,7888
$h = 7$	0,8379	0,7998	0,8034	0,7945	0,7972	0,8866	0,8238	0,7892	0,8622	0,7864	0,7670	0,8241	0,8272
$h = 8$	0,8144	0,7993	0,7995	0,7737	0,7774	1,1088	0,8062	0,7754	0,8722	0,7622	0,7537	0,8374	0,8363
$h = 9$	0,7972	0,7842	0,7829	0,7672	0,7674	1,0674	0,7970	0,7593	0,8242	0,7505	0,7403	0,8257	0,7690
$h = 10$	0,8843	0,8528	0,8474	0,8099	0,8104	1,1416	0,8515	0,8158	0,8528	0,8158	0,7905	0,9130	0,8238
$h = 11$	0,8519	0,8402	0,8463	0,8136	0,8251	1,3099	0,8480	0,8169	0,8459	0,8206	0,8188	0,8937	0,8254
$h = 12$	0,7619	0,7471	0,7542	0,7309	0,7355	1,0113	0,7717	0,7193	0,8107	0,7278	0,7739	0,7903	0,7860
acc3	0,9205	0,8405	0,8319	0,9285	0,9399	0,9480	0,8549	0,8349	0,9400	0,8331	0,8631	0,8879	0,9100
acc6	1,0581	1,0285	1,0133	1,0949	1,1136	1,1850	1,0192	1,0263	1,1317	1,0204	1,0145	1,0263	1,0890
acc12	0,8013	0,8201	0,8154	0,8583	0,8674	0,8203	0,8590	0,7998	1,1009	0,7998	0,8520	0,8053	0,8766

T.Factor = menor RMSFE em $h = 1$ (0,8735); EINET e LASSO = menores em $h = 2$ e $h = 3$; RF = menores em $h = 5$, $h = 7$, $h = 9$, $h = 10$.
acc3, acc6, acc12 = RMSFE sobre inflação acumulada em 3, 6 e 12 meses. Nenhum modelo supera o RW em acc6.

O 2SRR, estimado com $K_{\max} = 40$ fatores PCA, limiar de 90% de variância explicada e validação cruzada 5-fold, supera o Random Walk em todos os 12 horizontes individuais — o único modelo do conjunto com essa propriedade. Nos horizontes curtos ($h = 1$ a $h = 3$), modelos de regularização estática como EINET (0,832–0,747) e LASSO (0,832–0,749) apresentam RMSFE inferior ao 2SRR (0,943–0,803): a variação de parâmetros é menos vantajosa quando o sinal preditivo é mais persistente e o horizonte é curto. A partir de $h = 4$, o 2SRR passa a ser competitivo, registrando o menor RMSFE em $h = 4$ (0,782). O Bagging é o único modelo que *sistematicamente piora* o benchmark, superando 1,0 em seis dos doze horizontes e atingindo 1,310 em $h = 11$. Nos acumulados, nenhum modelo — incluindo o 2SRR (1,058) — supera o RW em acc6, sugerindo dificuldade generalizada de previsão semestral no período de 312 janelas.




Figura 1: RMSFE relativo ao Random Walk para todos os 13 modelos ($h = 1$ a $h = 12$). A linha tracejada representa $RW = 1$. O 2SRR ($K_{\max} = 40$, 90%, $k = 5$) é o único modelo consistentemente abaixo de 1 em todos os horizontes. O Bagging destoa negativamente, superando o benchmark em múltiplos horizontes.


2.2 Comparação 2SRR vs Ridge

A Tabela 2 apresenta a razão $\text{RMSFE}_{2\text{SRR}}/\text{RMSFE}_{\text{Ridge}}$ por horizonte. Razões abaixo de 1 indicam vantagem do 2SRR.

Tabela 2: Razão de RMSFE: 2SRR / Ridge por horizonte. Valores < 1 indicam vantagem do 2SRR sobre o Ridge.

Horizonte	2SRR	Ridge	Razão (2SRR / Ridge)
$h = 1$	0,9434	0,9047	1,043
$h = 2$	0,8360	0,8222	1,017
$h = 3$	0,8032	0,7976	1,007
$h = 4$	0,7816	0,8261	0,946
$h = 5$	0,7877	0,8056	0,978
$h = 6$	0,8190	0,8023	1,021
$h = 7$	0,8379	0,8241	1,017
$h = 8$	0,8144	0,8374	0,973
$h = 9$	0,7972	0,8257	0,965
$h = 10$	0,8843	0,9130	0,969
$h = 11$	0,8519	0,8937	0,953
$h = 12$	0,7619	0,7903	0,964
acc3	0,9205	0,8879	1,037
acc6	1,0581	1,0263	1,031
acc12	0,8013	0,8053	0,995

O 2SRR supera o Ridge em 8 dos 12 horizontes individuais. A vantagem é consistente a partir de $h = 4$, com exceção de $h = 6$ e $h = 7$, onde o Ridge apresenta RMSFE marginalmente inferior. O maior ganho relativo ocorre em $h = 4$ ($-5,4\%$), $h = 11$ ($-4,7\%$) e $h = 9$ ($-3,5\%$). Nos horizontes curtos ($h = 1$ a $h = 3$), o Ridge supera o 2SRR, o que é consistente com a maior eficiência do *shrinkage* fixo quando os coeficientes verdadeiros variam pouco no tempo. Esse padrão confirma que a adaptabilidade temporal do 2SRR tem valor econométrico crescente com o horizonte de previsão.




fig_2srr_vs_ridge.png

Figura 2: RMSFE relativo ao RW: 2SRR vs Ridge por horizonte. Nos horizontes $h \geq 4$, o 2SRR apresenta RMSFE consistentemente inferior ao Ridge (com exceção de $h = 6$ e $h = 7$), evidenciando que a variação de parâmetros agrega valor preditivo nos horizontes intermediários e longos.

2.3 Parâmetros Variantes no Tempo

A contribuição central do 2SRR frente a modelos com parâmetros fixos é a recuperação da trajetória temporal dos coeficientes $\hat{\beta}(t)$. A Figura 3 apresenta a evolução dos coeficientes das 10 variáveis de maior variância ao longo do período completo (1960–2025), para $h = 1$.



fig_betas_2SRR_tempo.png

Figura 3: Evolução de $\hat{\beta}(t)$ do 2SRR para $h = 1$ ($K_{\max} = 40$, 90%, $k = 5$), top 10 variáveis por variância dos coeficientes (1960–2025). Variáveis predominantes: índices de produção industrial (INDPRO, IPFINAL, IPDMAT, IPCONGD, IPDCONGD) e varejo (RETAILx). A amplitude dos betas aumenta expressivamente a partir de 2020.

Três regimes estruturais se destacam:

1. **Grande Inflação (1960–1985):** os coeficientes apresentam amplitude elevada e oscilações frequentes, refletindo a instabilidade da relação entre produção industrial e inflação no período anterior à desinflação Volcker.
2. **Grande Moderação (1985–2019):** a partir de meados dos anos 1980, os betas convergem para valores próximos de zero com menor variância, refletindo a estabilidade macroeconômica característica do período. A adoção de metas implícitas de

inflação pelo Federal Reserve contribui para a redução da sensibilidade dos preditores industriais à inflação.

3. **Ruptura pós-pandemia (2020–2025):** variáveis como IPFPNSS e IPDMAT voltam a apresentar coeficientes de grande magnitude, com o pico absoluto de $\hat{\beta} \approx 7.500$ em 2024–2025 — o maior de toda a série histórica. Esse comportamento captura o papel dos gargalos de oferta industrial no episódio inflacionário recente, cuja intensidade não tem precedente no período amostral.

Esse comportamento confirma a hipótese central de ? : a relação entre preditores e inflação é estruturalmente instável, e modelos com parâmetros fixos subestimam sistematicamente essa heterogeneidade temporal. Com $K_{\max} = 40$ fatores e 90% de variância explicada, o 2SRR captura um espectro mais amplo de informação macroeconômica do que especificações mais parcimoniosas, permitindo identificar quais dimensões do espaço de preditores são mais relevantes em cada regime.